Informe Final Integrador

Modelos de Aprendizaje Automático

Proyecto: Sistema Inteligente de Predicción de Demanda de Variedades y Planificación Logística para el Banco de Intercambio de Semillas / ProHuerta (Chascomús)

Integrantes: Barreu - Pérez Cazal - Quiroga

1. Definición del Problema y Objetivos

El programa ProHuerta en Chascomús enfrenta el desafío logístico de preparar kits de semillas sin conocer con antelación la diversidad de variedades que solicitará cada huertero/a. Preparar kits de más inmoviliza insumos limitados, mientras que preparar de menos genera desabastecimiento, demoras logísticas y una mala experiencia para los beneficiarios.

Objetivo del Modelo: Anticipar la demanda para determinar si es necesario preparar preventivamente un kit casi completo (alta demanda/diversidad) o un kit básico estandarizado. La predicción se realiza en el momento en que el usuario completa el formulario, antes del armado físico.

2. Auditoría y Preparación de Datos

Se consolidó un dataset basado en formularios de solicitud históricos abarcando las temporadas P-V 2024 hasta P-V 2026. Tras la limpieza y exclusión de datos con problemas de calidad (como registros sin detalle de variedades de 2022-2023), el universo de estudio quedó compuesto por 1.487 registros útiles.

- **Variables Predictoras:** 10 variables socio-productivas obtenidas al momento de la inscripción (ej. temporada, tipo de huerta, superficie, experiencia previa).
- **Exclusiones (Privacidad):** Se eliminaron datos personales directos (GPS, teléfono, e-mail) y la localidad, dado que el 97% corresponde a Chascomús, lo cual no aportaba varianza al modelo.

3. Diseño de la Variable Objetivo

El problema fue abordado desde dos enfoques metodológicos complementarios requeridos por la cátedra:

- **Enfoque de Regresión:** Predicción del volumen exacto demandado, medido como `especies_equivalentes` (cantidad de sobres o variedades).
- **Enfoque de Clasificación (Alerta de Alta Demanda):** Una variable binaria donde 1 representa "Alta Demanda" (cobertura del catálogo solicitada ≥ 75%) y 0 representa una demanda estándar. El umbral del 75% justifica logísticamente el empaquetado anticipado de un kit completo.

4. Preprocesamiento (Pipelines)

Para evitar el *data leakage* (fuga de información) y asegurar el correcto despliegue, todo el procesamiento se estructuró mediante `Pipelines` y `ColumnTransformer` de Scikit-Learn. Las variables categóricas fueron codificadas usando One-Hot Encoding, mientras que las numéricas (y promedios históricos) fueron estandarizadas con StandardScaler, asegurando que los modelos basados en distancias operaran correctamente.

5. Resultados del Modelado y Comparación

5.1. Predicción Numérica (Regresión)

Se evaluó la predicción exacta de sobres solicitados. El modelo seleccionado fue un **KNeighborsRegressor** (k=41, pesos uniformes). En las pruebas sobre el conjunto de testeo estratificado, se obtuvieron las siguientes métricas:

- **RMSE:** 3.39 sobres de error en promedio cuadrático.
- **MAE:** 2.60 sobres.

Un error absoluto medio de 2.6 sobres resulta altamente aceptable para la logística de la organización. Adicionalmente, el modelo logró superar al *baseline* histórico (promedio histórico barrial ajustado por un crecimiento demográfico del 5%), demostrando ser capaz de captar la varianza subyacente.

5.2. Comparación de Estrategias de Alerta (Clasificación vs Reglas)

Se implementaron dos estrategias para disparar alertas de alto consumo logístico:

Estrategia	Método Técnico	Ventajas Operativas
Regla sobre Regresor	Si (Predicción > Histórico × 1.1) Y (Diferencia ≥ 10) → Alerta	Permite ajustar los umbrales de sensibilidad logísticamente sin necesidad de reentrenar el modelo.
Clasificador Directo	DecisionTreeClassifier entrenado sobre variable binaria (cobertura ≥ 75%)	Aísla reglas lógicas directas sobre variables como superficie y tipo de huerta.

Evaluación de Costos: Dado que un "Falso Negativo" (no preparar el kit y dejar a una familia sin insumos) tiene un costo social estimado del doble respecto a un "Falso Positivo" (preparar un kit que no se retira, inmovilizando stock temporalmente), los hiperparámetros y umbrales fueron ajustados priorizando maximizar la sensibilidad (Recall) sobre la precisión (Precision).

6. Informe Técnico de Cambios: Variable Climática (Data Leakage)

Durante la auditoría de los modelos secundarios orientados a factores climáticos (influencia de lluvias en la demanda), se detectó un problema crítico de fuga de información. El modelo de regresión lineal original incluía la variable `Oferta_Catalogo`, la cual inflaba artificialmente las métricas ya que está directamente correlacionada con la variable objetivo, pero no está disponible para planificación a largo plazo.

Corrección Aplicada: Se rediseñó el modelo de impacto climático entrenando una **Regresión Lineal Simple** utilizando exclusivamente la variable de precipitaciones históricas (ej. 380 mm en Otoño-Invierno y 650 mm en Primavera-Verano) como predictor. Esto asegura predicciones robustas basadas verdaderamente en el estrés hídrico sin *target leakage*.

7. Despliegue en Producción y Frontend

Los modelos finales fueron serializados (`.joblib`) y se integraron a una aplicación web diseñada para el uso de los coordinadores territoriales.

- **Arquitectura Tecnológica:** La interfaz fue desarrollada de manera estática y respaldada por un backend en Flask, alojado en la plataforma Vercel.
- **Inferencia Eficiente:** Para ajustarse a los requerimientos de la cátedra y las limitaciones de hardware de la plataforma gratuita, la aplicación web **no realiza reentrenamiento en vivo** ni depende de una base de datos pesada. Carga los pesos paramétricos pre-entrenados y ejecuta la inferencia (método `.predict()`) en milisegundos.
- **Interfaz de Usuario (UI):** Se rediseñó el frontend para presentar las estimaciones de manera clara: una caja superior que muestra la cantidad de sobres previstos (Regresión) y un panel lateral que indica el semáforo de riesgo logístico (Sistema de Alertas).

8. Conclusiones

El proyecto logró desarrollar e implementar exitosamente un flujo completo de aprendizaje automático que resuelve un problema real de ineficiencia logística en el programa ProHuerta. Las principales conclusiones del trabajo son:

1. **Validación del Enfoque:** Las métricas demostraron que predecir el volumen de semillas a nivel individual utilizando características socio-productivas es superior a depender de medias históricas, reduciendo el margen de incertidumbre (MAE de 2.6 sobres).
2. **Escalabilidad del Sistema de Alertas:** La adopción de reglas dinámicas basadas en la predicción continua otorgó al equipo logístico municipal mayor flexibilidad operativa que un clasificador binario rígido.
3. **Robustez Técnica:** El uso extensivo de pipelines aseguró la integridad de los datos en producción, y la rápida rectificación del componente de lluvias garantizó el rigor analítico exigido.