Documento de Propuesta Oficial (Entrega 1)

Curso: Modelos de Aprendizaje Automático

Carrera: Ciencia de Datos e IA

Nombre del Proyecto: Sistema Inteligente de Predicción de Demanda de Variedades y Planificación Logística para el Banco de Intercambio de Semillas / ProHuerta (Chascomús)

Integrantes: *Barreu - Pérez Cazal - Quiroga*

---

1. Ficha Técnica de la Alternativa Principal (Proyecto Seleccionado)

- **Problema:** El programa arma y prepara kits de semillas sin conocer con antelación la diversidad de variedades que solicitará cada huertero/a. Preparar de más inmoviliza insumos; preparar de menos genera desabastecimiento y demoras logísticas.
- **Usuario de la Predicción:** Equipo técnico y coordinadores del Banco de Intercambio de Semillas, Promotores Territoriales y Dirección de Ambiente (Chascomús).
- **Decisión que permitirá tomar:** Antes de la entrega, determinar cuántas variedades reservar por solicitante y definir a quiénes preparar preventivamente un kit casi completo (alta demanda/diversidad) vs. un kit básico estandarizado.
- **Qué representa cada fila:** Una solicitud individual de retiro de semillas realizada por un responsable de huerta (familiar o institucional) en una temporada.
- **Momento exacto de la predicción:** Al momento en que el participante completa el formulario de solicitud/retiro, antes de la selección, armado y entrega física de los sobres.
- **Variable Numérica (Regresión):** Cobertura del Catálogo (%).
  $$Cobertura\ del\ Catálogo(\%) = \frac{Variedades\ distintas\ solicitadas}{Variedades\ ofrecidas\ en\ esa\ temporada} \times 100$$
  Rango continuo de 0% a 100%.
- **Variable Binaria (Clasificación - Alerta):**
  - **1** = Alta Demanda / Alta Diversidad (si Cobertura ≥ 75%).
  - **0** = Demanda Estándar / Acotada (si Cobertura < 75%).
- **Justificación del Umbral:** El 75% representa haber solicitado al menos 3 de cada 4 variedades ofrecidas (un kit casi completo). Es el punto de inflexión donde al programa le conviene empaquetar el kit completo por adelantado. El umbral se fija a priori según criterio técnico del programa.

- **Fuente de Datos:** Formularios de solicitud/retiro del ProHuerta / Banco de Semillas de Chascomús, abarcando 5 temporadas: P-V 2024, O-I 2025, P-V 2025, O-I 2026 y P-V 2026.
- **Registros Utilizables:** 1.487 solicitudes con detalle de variedades (dentro de un acervo histórico municipal de 2.730 filas).
- **Variables Predictoras Disponibles:** 10 predictores socio-productivos capturados estrictamente en el formulario de inscripción.

---

2. Tres Alternativas Evaluadas

Cumplimiento formal de los apartados 1.1 y 3.1 de la consigna.

Campo	A. Cobertura del Catálogo	B. Tasa de Germinación y Éxito de Siembra	C. Volumen de Kits Entregados
Problema	Anticipar el % de variedades que pedirá cada huertero para optimizar stock y logística.	Detectar huertas con riesgo de baja germinación para enviar asistencia técnica.	Predecir cuántos kits físicos retira cada beneficiario.
Usuario	Coordinadores y promotores del Banco de Semillas.	Promotores técnicos de campo.	Coordinadores logísticos.
Decisión	Preparar kits completos anticipados vs. kits básicos.	Programar visitas preventivas de acompañamiento.	Planificar compra y embalaje de cajas de kits.
Variable Numérica	Cobertura Porcentual del Catálogo (%).	Porcentaje de especies sembradas que germinaron (%).	Cantidad total de kits entregados.
Umbral / Alerta	Cobertura ≥ 75% (Kit completo / Alta demanda).	Germinación < 70% (Alerta de pérdida de cultivo).	Kits entregados ≥ 2 (Alta escala).
Fuente y Tamaño	Formularios 2024–2026: 1.487 registros con objetivo válido.	Relevamientos 2023–2024: < 100 registros con dato de germinación.	Registros 2022–2023: 1.045 filas.

Variables Disponibles	10 predictores socio-productivos de la inscripción.	Tipo de suelo, riego, abono (medidos post-siembra).	Localidad, superficie, destino.
Riesgos y Limitaciones	Modificación de la oferta estacional de semillas.	Muestra insuficiente (< 100 casos) y sesgo de respuesta.	El 90% de los registros retira exactamente 1 kit (sin varianza).
Veredicto	**Elegida.**	Descartada por falta de datos (< 2000 y sin variable en 2025-2026).	Descartada por variabilidad nula y datos sensibles.

---

3. Predictores Disponibles y Prevención de Fuga de Información

Predictores Válidos (Disponibles en t=0)

- **Estación / Temporada:** Categórica (*Otoño-Invierno, Primavera-Verano*).
- **Variedades Ofrecidas en el Catálogo:** Numérica (*9, 12, 17, 18 especies según la temporada*).
- **Tipo de Huerta:** Categórica (*Familiar, Institucional*).
- **Tipo de Localización:** Categórica (*Urbana, Periurbana, Rural / Paraje*).
- **Antigüedad / Experiencia:** Ordinal (*Primera vez, 1 a 3 años, Más de 3 años*).
- **Superficie Destinada:** Ordinal (*Hasta 5 m², 6 a 20 m², Más de 20 m²*).
- **Destino de la Producción:** Categórica (*Autoconsumo, Intercambio / Trueque, Venta / Comercial*).
- **Ocupación del Huertero/a:** Categórica (*Agrupada por bloques sociolaborales*).
- **Interés en Comunicación Técnico-Informativa:** Categórica (*Grupo WhatsApp Huerta, Compostaje*).
- **Preferencia de Contacto / Visita:** Categórica (*Mañana, Tarde, Ambos*).

Variables Excluidas (Fuga de Información o Privacidad)

- **Lista textual de variedades retiradas:** Se excluye por ser la variable objetivo.
- **Seguimiento post-entrega (germinación, siembra, cosecha, devolución):** Se excluyen porque suceden con posterioridad a la predicción.

- **Datos de Identificación / Ubicación Precisa:** Mail, coordenadas GPS, barrio, dirección exacta y teléfono. Se descartan para proteger la privacidad y cumplir la condición de datos no identificables.
- **Localidad:** Se descarta debido a que el 97% de los casos corresponden a Chascomús (comportamiento constante).

---

4. Esquema de Costos y Tolerancia al Error

Sección 1.2.3 de la Consigna.

- **Falso Positivo (FP):** El modelo predice Alta Demanda (≥ 75%), pero la persona retira un kit acotado.
    - *Consecuencia:* Se preparó un kit extendido por adelantado que no se retira completo; las semillas quedan reservadas transitoriamente pero se reasignan fácilmente al siguiente solicitante.
    - *Costo asignado:* **1 unidad**.
- **Falso Negativo (FN):** El modelo predice Demanda Estándar (< 75%), pero la persona solicitaba un kit completo.
    - *Consecuencia:* Faltan insumos al momento de la atención, la familia se retira con variedades incompletas, se frustra la siembra diversificada o se obliga a realizar un segundo viaje.
    - *Costo asignado:* **2 unidades** *(el doble que el FP)*.

$$Costo\ Total\ del\ Sistema = (1 \times FP) + (2 \times FN)$$

> **Estrategia de Optimización:** Se priorizará maximizar el **Recall (Sensibilidad)** sobre el *Precision* para minimizar la ocurrencia de Falsos Negativos, protegiendo el impacto social del programa.

---

5. Bitácora de Decisiones Iniciales

Fecha	Decisión	Alternativas Evaluadas	Justificación Técnico-Metodológica	Resultado
15/10/2026	Selección de la Cobertura del Catálogo (%) como variable objetivo continua.	Variedades absolutas (≥ 6), Volumen por Barrio, Germinación.	Mantiene la métrica comparable ante los cambios de catálogo entre 2024 y 2026.	**Adoptada**
15/10/2026	Filtrado del Dataset a las temporadas 2024–2026 (1.487 registros).	Incluir 2022–2023 sin variedades.	Las temporadas 2022–2023 no poseen el desglose de variedades.	**Adoptada**
15/10/2026	Definición del umbral binario en 75% de cobertura.	Umbrales del 50%, 60% o 80%.	Equivale a un kit casi completo (3 de 4 especies) y balancea las clases (≈ 39% positivos).	**Adoptada**
15/10/2026	Asignación de esquema de costos FN : FP = 2 : 1.	Costos simétricos 1 : 1.	Dejar a una familia sin semillas afecta directamente el propósito socio-alimentario.	**Adoptada**
15/10/2026	Consulta docente en Clase 1 por el tamaño del dataset (1.487 observaciones).	Agrupar por barrio para intentar inflar/reestructurar.	Se debe preservar la unidad de análisis individual sin distorsionar los datos.	**Pendiente de confirmación**